

ThierryNum-ENC

Pré-indexation automatique des premiers lots de numérisations du fonds Nicole et Jean-Michel Thierry de l'INHA: Institut national d'histoire de l'art

Hackathon ENC-PSL 5-9 janvier 2026

Projet réalisé par Denise Atzori, Thaïs Raffray et Chiara Tedesco

CONTEXTE

Le fonds Nicole et Jean-Michel Thierry: environ 100 000 photographies, films et dossiers de documentation et de recherche - 1950-2017. Un premier volet de numérisations sur le patrimoine arménien et géorgien, destiné à être documenté par une communauté d'experts.

CORPUS ET DONNÉES

- 297 lots d'archives structurés en manifestes IIIF et présentant un corpus de 8196 vues
- Une fraction du corpus de 1335 vues enrichies manuellement par des mots-clés scientifiques [[modèle de données créé par campagne d'annotation experte participative](#)]

OBJECTIFS

- Classer automatiquement 8196 vues selon:
 - Types de vue
 - Sujets représentés
- Générer des titres longs pour les images

STRATÉGIE

- Entraînement d'un modèle supervisé (YOLO nano v11) sur les images annotées par l'équipe de recherche pour le premier niveau d'annotation et benchmarking

- Benchmarking de modèles non-supervisés pour la classification des sujets du deuxième niveau d'annotation (CLIP, EfficientNet, DINO-v2, ViT)
- Inférences sur les images non annotées pour comparer les résultats des modèles
- Création d'une interface graphique avec la librairie Python streamlit pour la validation manuelle des annotations automatiques
- Benchmarking des modèles pour la génération des descriptions (Qwen3-Max, ministral-8b-2512, mistral-medium-2508, pixtral-12b-2409)

DIFFICULTÉS RENCONTRÉES

- Erreurs dans les annotations manuelles de certaines images (elle ne suit pas toujours les nœuds de l'arborescence) -> solution: correction avec un script
- Pas assez de données annotées pour chaque classe dans le niveau 2 -> solution: clustering non-supervisé pour le tag 2

CODE GÉNÉRÉ

- 1-extraction_annotations.ipynb: scrapping des images avec annotations manuelle et création CSV
- 2-training_yolo_tag1.ipynb: pré-processing données et entraînement Yolov11n-cls pour le premier niveau
- 3-training_yolo_tag2.ipynb: pré-processing données et entraînement Yolov11n-cls pour le deuxième niveau
- 4-inference_yolo.ipynb: inférence avec Yolo et production du csv
- 5-merge_inference_images_csv.ipynb: script pour ajouter les inférences de Yolo sur le csv
- 6-clustering_dino.ipynb: inférence et clustering (non-supervisé) avec Dinov2 pour le deuxième niveau
- 7-clustering_efficientnet.ipynb: inférence et clustering (non-supervisé) avec EfficientNetv7 pour le deuxième niveau
- 8-fusionner_clustering_images.ipynb: script pour fusionner les résultats du clustering (tag_2) dans le CSV des images
- 9-lanahid.py: app streamlit pour la validation manuelle des annotations et la génération des légendes(à lancer avec les instructions dans instruction_streamlit.txt)

COMPTE-RENDU DÉTAILLÉ DU TRAVAIL RÉALISÉ

Lundi 5 janvier 202

Prise de connaissance du projet, des attendus, du modèle et du jeu de données

Mardi 6 janvier 2026

À partir du fichier JSON fourni, extraction des images et des annotations associées dans un fichier CSV. Extraction et téléchargement uniquement des fichiers images annotés à partir du CSV réalisé.

Réalisation d'un script qui déplace chaque image dans un dossier correspondant à son annotation (Type de vue : "Photographie", "Matériel de conditionnement", etc)

Réalisation d'un script qui permet de redimensionner les images afin d'obtenir des fichiers plus légers pour l'entraînement du modèle YOLO et création du dataset (80% train, 20% val)

Entraînement d'un modèle d'apprentissage supervisé (YOLO nano v11): accuracy de 94%

Mercredi 7 janvier 2026

Benchmarking du modèle YOLO (tag_1) en apportant des modifications au dataset d'entraînement. Données originelles: 1383 images dans lesquelles: 1226 photographie, 32 reproduction de plan arch., 50 autre document (graveurs etc), 50 matériel de cond., 3 autre.

- Benchmark_1 : rééquilibrage du dataset en utilisant seulement 613 "Photographies" (moitié) → **modèle plus précise**
- Benchmark_2 : rééquilibrage du dataset en utilisant seulement 60 "Photographies" (quantité d'informations plus proche à celle dans les autres catégories)
- Benchmark_3 : rééquilibrage du dataset en utilisant seulement 469 "Photographies" (choisies parmi celles que le modèle n'avait pas déjà vues)

[notes après les benchmark: pas d'importantes différences dans les résultats; avec le données déjà annotées, le modèle a la tendance à se concentrer sur les photographies: il détecte cette classe très bien mais il a toujours une petite pourcentage des photos dans les autres catégories: voir confusion_matrix dans le dossier Yolo_best-unbalanced sur Github pour le modèle le plus précise]

Inférence du modèle YOLO (tag_1) sur les images non annotées.

Réalisation d'un script qui résout la question des nœuds manquants dans l'arborescence des annotations.

Entraînement du modèle YOLO pour le tag_2, utilisant seulement le type de vue "Photographie": les catégories du dataset sont trop déséquilibrés à ce niveau (normal dans le corpus, mais cela pose des problèmes dans l'entraînement du modèle YOLO: trop peu de données pour un modèle supervisé).

Entraînement de modèles d'apprentissage non-supervisé pour faire du clustering pour le tag_2 (CLIP, EfficientNet, DINO-v2, ViT) avec un échantillon d' environ 80 images (20 pour chaque catégorie). BLiP n'a pas été utilisé car il est trop lourd. Nous avons écarté CLIP car le taux de réussite était inférieur à 20%.

L'apprentissage non supervisé permet d'obtenir un premier dégrossissement du corpus, mais un modèle entraîné sur des images annotées sera toujours plus performant.

Jeudi 8 janvier 2026

Benchmarking du modèle YOLO (tag_1) avec les nouvelles données obtenues par l'inférence:

- Benchmark_4 : dataset avec environ 100 images pour chaque catégorie à l'exception de Autre → **plus équilibré mais avec moins precision sur photographie**
- Benchmark_5 : dataset avec 200 images pour photographie et environ 100 images pour les autres catégories à l'exception de Autre: pas des changement significatifs

[note après les benchmark: en ajoutant les données inférées, le modèle est meilleur sur la détection des classes sous-représentés dans l'annotation manuel; par contre, la précision est mineure; voir confusion_matrix dans le dossier Yolo_best-balanced sur Github. Nous suggérons de choisir entre le benchmark_1 et le benchmark_4 en fonction du task].

Traitement des clustering obtenues pour le tag_2 avec EfficientNet et Dino-v2 (considérés comme les meilleurs modèles entre ceux testés après observations des résultats). Créations des fichiers csv avec inférence et clustering pour la visualisation.

Développement d'une appli avec streamlit pour la validation manuelle des annotations automatiques (voir Documentation → instruction_IAnahid.txt pour les instructions)

Génération de légendes pour les photographies:

- quelques essais de génération de légende avec le chat de Qwen (version Qwen3-Max). La performance est idéale, mais le modèle est très lourd et il s'agit d'une solution très compliquée à mettre en œuvre sur un large corpus
- testé plusieurs modèles Mistral :

- minstral-8b-2512 : meilleur globalement, le moins cher avec de bons résultats
- mistral-medium-2508 : un peu plus cher, résultats équivalents
- pixtral-12b-2409 : plus adapté aux images, mais plus cher et résultats un peu moins bons

Avec le modèle minstral-8b-2512 le coût de la génération de légende est de €0,02 par image. Nous avons estimé que le coût pour 30 000 images serait d'environ €600. Une alternative est de générer la légende seulement pour un échantillon d'images (ex, 500), et ensuite d'entraîner un modèle de génération de légende spécialisé qui puisse tourner en local.

Règles pour le prompt :

- *Décrire uniquement les éléments visuellement observables (architecture, matériaux, organisation spatiale, objets, personnes, vêtements, gestes, inscriptions, paysage).
- *Ne pas interpréter le sens, la fonction, le symbolisme, les rôles sociaux, les croyances, les émotions ou le contexte historique.
- *Ne pas identifier de groupes ethniques, de religions ou d'identités culturelles.
- *Ne pas supposer de dates, de lieux, d'événements ou d'usages.
- *Ne pas inférer ce qui ne peut être déterminé visuellement.
- *Employer un langage précis, neutre et documentaire.
- *Rédiger en phrases complètes, sous forme de paragraphe (pas de liste).
- *2-3 lignes maximum
- Structure de la description :
 - 1 Environnement bâti et éléments architecturaux
 - 2 Contexte spatial et paysage environnant
 - 3 Objets et matériaux
 - 4 Figures humaines (le cas échéant)
 - 5 Animaux (le cas échéant)

Sortie attendue : Une légende unique et développée (2-3 lignes max), adaptée à un catalogue d'archive patrimoniale.

Ajoute de la fonction pour la génération des légendes dans l'appli: l'utilisateur peut choisir lequel de trois modèles mistral utiliser; l'application permet de saisir une clé API Mistral et de lancer une génération de légende image par image (à chaque démarrage on doit saisir la clé).

Création du dossier Github.

Vendredi 9 janvier 2026

Écriture de la documentation, préparation des slides, présentation des résultats.