

HACKATHON 2026

PROJET THIERRYNUM

DENISE ATZORI, THAÏS RAFFRAY, CHIARA TEDESCO

CONTEXTE

Le fonds Nicole et Jean-Michel Thierry:


*env. 100 000 photographies, films et dossiers de
documentation et de recherche – 1950–2017.*

*Un premier volet de numérisations sur le patrimoine
arménien et géorgien, destiné à être documenté par une
communauté d'experts.*

RAPPEL DES OBJECTIFS

- Classification automatique des images selon les types de vues et le sujets représentés.
- Génération automatique de titres longs, selon un modèle donné.

PIPELINE





DESCRIPTION DU DATASET

Corpus de 8196 vues.

Échantillon annoté manuellement de 1335 vues.

L'annotation est constituée de 5 classes dans le premier niveau (Tag1), et 6 dans le deuxième (Tag2). À prendre en compte : les classes sont très déséquilibrées entre elles.

PROBLÈMES RENCONTRÉS




PROBLEME 1

- Dataset déséquilibré par nature : problèmes posés pour l'entraînement de Yolo.

PROBLEME 2

- Souci dans l'annotation des images : attention à bien vérifier que la hiérarchie des niveaux de labélisation est bien respectée avant de lancer les modèles.
- Attention parfois labels manquants.

DESCRIPTION DES RÉSULTATS




RÉSULTATS 1

- Benchmarking du modèle Yolo pour le premier niveau d'annotation. Pour le dataset tel quel et le dataset rééquilibré.
- Benchmarking du modèle Yolo pour le deuxième niveau d'annotation.

RÉSULTATS 2


- Benchmarking de modèles d'apprentissage non supervisé: Dino V2, Efficientnet, ViT.
- Génération automatique de légende avec l'API Mistral.
- Réalisation d'une interface graphique de correction manuelle




Yolo_best-unbalanced
accuracy: 0.969

YOLO TAG-1

Yolo_best-balanced
accuracy: 0.882



YOLO TAG-2



accuracy: 0.927

B751025206PH04PHOT68_bureauJMT_01_8_2_009.jpg

B751025206PH04PHOT68_bureauJMT_01_8_2_009.jpg



B751025206PH04PHOT68_saloon_14_22_019.jpg



B751025206PH04PHOT68_saloon_14_22_023.jpg



CLUSTERS EFFICIENTNET

B751025206PH04PHOT68_bureauJMT_01_7_5_013.jpg



B751025206PH04PHOT68_bureauJMT_01_7_5_023.jpg

B751025206PH04PHOT68_bureauJMT_01_7_5_029.jpg

B751025206PH04PHOT68_bureauJMT_01_7_5_020.jpg



B751025206PH04PHOT68_bureauJMT_01_7_5_024.jpg



	A	B	C
	clustering_results_efficientnet		
1	title	image_url	clustering_id
2	1109_doucet_4PHOT68_bureauJMT_01_4_10_000005.jpg	1109_doucet_4PHOT68_bureauJMT_01_4_10_000005.jpg	8
3	1109_doucet_4PHOT68_salon_14_22_000004.jpg	1109_doucet_4PHOT68_salon_14_22_000004.jpg	3
4	B751025206PH04PHOT68_bureauJMT_01_7_5_003.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_003.jpg	0
5	B751025206PH04PHOT68_bureauJMT_01_7_5_005.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_005.jpg	0
6	B751025206PH04PHOT68_bureauJMT_01_7_5_009.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_009.jpg	1
7	B751025206PH04PHOT68_bureauJMT_01_7_5_012.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_012.jpg	0
8	B751025206PH04PHOT68_bureauJMT_01_7_5_013.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_013.jpg	0
9	B751025206PH04PHOT68_bureauJMT_01_7_5_016.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_016.jpg	1
10	B751025206PH04PHOT68_bureauJMT_01_7_5_020.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_020.jpg	0
11	B751025206PH04PHOT68_bureauJMT_01_7_5_023.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_023.jpg	0
12	B751025206PH04PHOT68_bureauJMT_01_7_5_024.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_024.jpg	0
13	B751025206PH04PHOT68_bureauJMT_01_7_5_028.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_028.jpg	1
14	B751025206PH04PHOT68_bureauJMT_01_7_5_029.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_029.jpg	0
15	B751025206PH04PHOT68_bureauJMT_01_7_5_032.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_032.jpg	0
16	B751025206PH04PHOT68_bureauJMT_01_7_5_033.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_033.jpg	0
17	B751025206PH04PHOT68_bureauJMT_01_7_5_034.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_034.jpg	0
18	B751025206PH04PHOT68_bureauJMT_01_7_5_035.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_035.jpg	0
19	B751025206PH04PHOT68_bureauJMT_01_7_5_039.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_039.jpg	0
20	B751025206PH04PHOT68_bureauJMT_01_7_5_040.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_040.jpg	1
21	B751025206PH04PHOT68_bureauJMT_01_7_5_041.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_041.jpg	1
22	B751025206PH04PHOT68_bureauJMT_01_7_5_042.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_042.jpg	0
23	B751025206PH04PHOT68_bureauJMT_01_7_5_043.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_043.jpg	0
24	B751025206PH04PHOT68_bureauJMT_01_7_5_044.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_044.jpg	0
25	B751025206PH04PHOT68_bureauJMT_01_7_5_045.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_045.jpg	0
26	B751025206PH04PHOT68_bureauJMT_01_7_5_046.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_046.jpg	0
27	B751025206PH04PHOT68_bureauJMT_01_7_5_047.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_047.jpg	0
28	B751025206PH04PHOT68_bureauJMT_01_7_5_048.jpg	B751025206PH04PHOT68_bureauJMT_01_7_5_048.jpg	0
29	B751025206PH04PHOT68_bureauJMT_01_8_1_007.jpg	B751025206PH04PHOT68_bureauJMT_01_8_1_007.jpg	0
30	B751025206PH04PHOT68_bureauJMT_01_8_1_008.jpg	B751025206PH04PHOT68_bureauJMT_01_8_1_008.jpg	2
31	B751025206PH04PHOT68_bureauJMT_01_8_1_009.jpg	B751025206PH04PHOT68_bureauJMT_01_8_1_009.jpg	2

L'APPLICATION IANAHID

Interface pour la visualisation des images, la
correction de l'indexation automatique des images,
et la génération automatique de légendes.

Configuration

Mode de travail :

- ☒ tag_1
- ☐ tag_2
- ☐ Légende (IA)
- ☐ Validation par Cluster

API Mistral

Clé API Mistral

.....

Modèle

ministral-8b-2512

Images validées


0 / 1383

↑ 0%

Mode : tag_1

PRÉCÉDENT

SKIP / SUIVANT (Sans valider)



ID: B751025206PH04PHOT68_bureauJMT_01_7_5_001 | Cluster: nan

Valeur actuelle: 1.4. Matériel de conditionnement

✓ VALIDER CETTE ATTRIBUTION

✗ MODIFIER LA CATÉGORIE

✓ Voir tableau complet

titre	image_url	clustering_id	tag_1	tag_2	tag_3	tag_4	tag_5	tag_6	tag_7	tag_8	tag_9	validated_tag_1	validated_tag_2	validated_tag_3
-------	-----------	---------------	-------	-------	-------	-------	-------	-------	-------	-------	-------	-----------------	-----------------	-----------------

PROCHAINES ÉTAPES

- Appliquer la pipeline au reste du corpus non annoté.
- Étendre la pipeline à tous les niveaux successifs de l'annotation.

